Politechnika Białostocka

Eksploracja Zasobów Internetowych

Badanie struktury sieci WWW i struktur do przechowywania treści pozyskanych ze stron WWW

I. Badanie struktury sieci WWW

1. W aplikacji WebSPHINX zbudować graf dowolnej strony (zakładka *Crawl*). Strona powinna zawierać co najmniej trzy poziomy głębokości i co najmniej dwadzieścia podstron. Dokonać charakterystyki otrzymanego grafu, określając: głębokość grafu, liczbę linków znajdujących się na stronie głównej oraz na podstronach, itp.
2. Wykonać punkt 1 przy zmianie następujących parametrów w zakładce *Advanced*:
   1. zmiana strategii przeglądania struktury (*hops*): Breadth first,
   2. tryb przeglądania (*Crawl*): server, web,
   3. oznaczane elementy (*Using*): images+hyperlinks, all links.
3. Przeanalizować wpływ zmiany poszczególnych parametrów na wynik przeszukiwania.
4. Określić, która kombinacja parametrów jest najlepsza pod kątem praktycznym i dlaczego.

II. Badanie struktur do przechowywania treści pozyskanych ze stron WWW

5. Wykorzystać aplikację Win Web Crawler do zapisania treści stron WWW:
   1. Stworzyć nową sesję: menu File → New Session.
   2. W zakładce General wybrać korzystanie z podanego adresu URL – Source: WebSite/Dirs. Ustawić adres startowy na ustaloną wcześniej stronę.
   3. Ustawić opcję zapisu do pliku w formacie CSV zbioru wartości URL (Save Data in CSV Format) oraz Extract URL, MetaTag (title, desc, keyw, body).

4. Przejść do zakładki External Site. Ustawić przechodzenie do adresów zewnętrznych (Follow External URLs). Odznaczyć przeglądanie tylko jednej strony (Process 1 Page only).
5. Ustawić głębokość podążania za łączami (Retrieval Depth of Each URL) na wartość 2.
6. Zapisać dane (Zakładka Data → Save Data), ustalając format separatora (Seprator Format) na CSV oraz wybierając do zapisu pola (Save Field) URL, Keyword.

6. Określić przydatność utworzonej w punkcie 6 struktury i zapisanych w niej danych pod kątem pozyskiwania wiedzy o strukturze i zawartości sieci WWW.
7. Na podstawie tej samej strony początkowej wygenerować bazę o innej strukturę i/lub treści, poprzez zmianę wartości dowolnych parametrów.
8. Określić różnice pomiędzy dwoma bazami pod względem ich budowy i zawartości oraz pod względem ich zastosowań.